T7. Descripción de escenas controladas con modelos multimodales: VLMs autoregresivos frente a VL-JEPA

Guía: Jhon Intriago.

Descripción: Un modelo de lenguaje multimodal (VLM) recibe una imagen y un prompt, y produce texto. La pregunta práctica es qué tan fiel es ese texto a lo que realmente hay en la imagen. En datos naturales esto es difícil de medir, porque no existe una descripción "correcta" única. Este proyecto usa en cambio un conjunto sintético donde cada imagen fue generada a partir de un conjunto pequeño de atributos conocidos (forma, color, posición y ángulo del objeto, color del foco y del fondo), y donde el texto de referencia describe explícitamente esos atributos. Eso permite comparar la descripción generada contra la verdadera atributo por atributo, y no solo con métricas de similitud textual.

El proyecto se desarrolla en dos etapas:

1. Inferencia sin ajuste. Se evalúa cada modelo tal como viene preentrenado, con distintos prompts, midiendo cuánto se aproxima el texto generado al de referencia. Esto establece el punto de partida y expone el desajuste entre el dominio de preentrenamiento (imágenes web) y el dominio sintético del conjunto.

2. Ajuste fino y comparación. Se hace *fine-tuning* de los tres modelos sobre el mismo conjunto y con el mismo presupuesto de cómputo, y se vuelve a medir. La comparación entre las dos etapas es tan informativa como la comparación entre modelos: indica cuánto del error inicial era falta de conocimiento y cuánto era simple desalineamiento de formato.

Los tres modelos a comparar:

- **LLaVA** [2] como línea base: encoder visual congelado, proyector lineal y decodificador de lenguaje.
- **Un VLM moderno superior a LLaVA** (Qwen2.5-VL [3] o InternVL 3 [4]), con conector más expresivo y resolución dinámica. Permite separar qué limitaciones vienen del paradigma autoregresivo y cuáles solo de una arquitectura antigua.
- **VL-JEPA** [5]: en lugar de generar tokens, predice el embedding continuo del texto objetivo a partir de la imagen y de la consulta, e invoca un decodificador ligero solo cuando se necesita texto legible. Es una forma distinta de resolver la misma tarea y el punto de contraste central del proyecto.

Todos los modelos se usan **preentrenados y cuantizados** (4-8-bit NF4 o AWQ), con adaptación mediante LoRA. No se entrena nada desde cero. Si alguno de los modelos resulta suficientemente bueno, todo el framework puede adaptarse a datos clínicos reales del Instituto de Neurocirugía.

Métricas. Además de las métricas estándar de generación (BLEU, ROUGE, CIDEr), se debe reportar **exactitud por atributo**: extraer de la descripción generada el valor de cada atributo y compararlo con el verdadero. Esta es la medida que realmente responde la pregunta del proyecto, ya que un texto puede parecerse mucho al de referencia y equivocarse justo en el color o la posición.

Preguntas a resolver:

- Sin ajuste fino, ¿qué tan lejos está el texto generado del de referencia, y en qué atributos falla cada modelo?
- ¿Qué atributos son sistemáticamente más difíciles (posición y ángulo frente a color y forma), y por qué?
- ¿Cuánto mejora cada modelo con *fine-tuning*, y cuál converge con menos datos o menos pasos?
- ¿Se traduce la ventaja del VLM moderno sobre LLaVA en mejores descripciones, o solo en texto mejor formado?
- ¿Predecir en espacio de embeddings, como VL-JEPA, da ventaja en esta tarea frente a generar tokens? ¿A qué costo en calidad del texto final?
- ¿Cómo evaluar de forma justa a VL-JEPA, cuyo texto pasa por un decodificador de lectura adicional?
- ¿Cómo afecta la cuantización a la calidad de las descripciones y al comportamiento durante el ajuste?
- ¿Qué revela la sensibilidad al prompt sobre lo que cada modelo realmente extrae de la imagen?

Datos: Multimodal3DIdent [1], conjunto de imágenes renderizadas y descripciones textuales con atributos generativos conocidos y controlados. Se usa tanto el conjunto publicado como su generador, lo que permite construir variantes (nuevas combinaciones de atributos, conjuntos fuera de distribución, descripciones con más o menos detalle) para probar generalización.

Software disponible: PyTorch (Hugging Face Transformers, PEFT, bitsandbytes)
Dificultad: Alta
Código Bases:
Generador y datos Multimodal3DIdent
LLaVA
VL-JEPA
Código del Proyecto: GitLab (Pedir Acceso a Tutor)

Bibliografía:
[1] I. Daunhawer, A. Bizeul, E. Palumbo, A. Marx, J. E. Vogt, "Identifiability Results for Multimodal Contrastive Learning," *ICLR*, 2023. arXiv:2303.09166.
[2] H. Liu, C. Li, Q. Wu, Y. J. Lee, "Visual Instruction Tuning," *NeurIPS*, 2023. arXiv:2304.08485.
[3] S. Bai et al., "Qwen2.5-VL Technical Report," 2025. arXiv:2502.13923.
[4] Z. Chen et al., "InternVL: Scaling up Vision Foundation Models and Aligning for Generic Visual-Linguistic Tasks," *CVPR*, 2024. arXiv:2312.14238.
[5] D. Chen et al., "VL-JEPA: Joint Embedding Predictive Architecture for Vision-language," 2025. arXiv:2512.10942.
[6] A. Radford et al., "Learning Transferable Visual Models From Natural Language Supervision," *ICML*, 2021. arXiv:2103.00020.
[7] E. J. Hu et al., "LoRA: Low-Rank Adaptation of Large Language Models," *ICLR*, 2022. arXiv:2106.09685.
[8] T. Dettmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer, "QLoRA: Efficient Finetuning of Quantized LLMs," *NeurIPS*, 2023. arXiv:2305.14314.
[9] P. Anderson, B. Fernando, M. Johnson, S. Gould, "SPICE: Semantic Propositional Image Caption Evaluation," *ECCV*, 2016. arXiv:1607.08822.